



UNIVERSIDADE FEDERAL DO ABC
CMCC – CENTRO DE MATEMÁTICA, COMPUTAÇÃO E COGNIÇÃO
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

Victor Cobo Figueiro

Filtro de Dados e Compressão para Computação em Névoa em IoT na Agricultura Inteligente utilizando Rust e WebAssembly

Santo André
2026

Victor Cobo Figueiro

Filtro de Dados e Compressão para Computação em Névoa em IoT na Agricultura Inteligente utilizando Rust e WebAssembly

Projeto de Graduação em Computação apresentado ao Bacharelado em Ciência da Computação da Universidade Federal do ABC, como requisito parcial para a obtenção do título de Bacharel.

UNIVERSIDADE FEDERAL DO ABC
CMCC – CENTRO DE MATEMÁTICA, COMPUTAÇÃO E COGNIÇÃO
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

Orientador: Prof. Dr. Carlos Alberto Kamienski

Santo André
2026

Dedico este trabalho à minha família pelo apoio incondicional, aos meus colegas de curso pelas noites de estudo compartilhadas, e a todos que enxergam na computação uma ferramenta para transformar a interação humana com o meio ambiente.

Agradecimentos

Agradeço primeiramente ao meu orientador, Prof. Dr. Carlos Alberto Kamienski, pelo suporte técnico, paciência e pelas valiosas discussões acadêmicas ao longo do desenvolvimento deste projeto. Agradeço à Universidade Federal do ABC pelo ensino público de excelência e a todos os professores que contribuíram para minha formação científica. Por fim, aos meus amigos e familiares, cujo encorajamento foi essencial nesta jornada.

*“A tecnologia é apenas uma ferramenta. No que diz respeito a fazer as crianças
trabalharem juntas e motivá-las, o professor é o mais importante.”*
(Bill Gates)

Resumo

A agricultura inteligente é uma das principais fronteiras da Internet das Coisas (IoT), exigindo o monitoramento de variáveis físicas contínuas em ambientes remotos. Contudo, a transmissão em tempo real de grandes volumes de dados de sensores para a nuvem por canais de baixa potência e banda restrita (como LoRaWAN) gera alta latência, congestionamento e rápido esgotamento energético dos dispositivos. Como continuação direta e implementação prática da pesquisa teórica proposta por Ribeiro Junior et al. (JUNIOR et al., 2020), este trabalho propõe e avalia um ecossistema de computação em névoa baseado em Rust e WebAssembly (WASM) para realizar filtragem e compressão de dados na borda da rede. Utilizando o algoritmo de classificação k -Vizinhos Mais Próximos (k NN, com $k = 3$) adaptado para as condições agronômicas de cultivo do tomateiro, o sistema converte medidas físicas contínuas de temperatura e umidade em status discretos de um caractere, os quais são posteriormente comprimidos via Run Length Encoding (RLE). Para a validação estatística, implementou-se um gerador de dados estocásticos via Estimativa de Densidade por Kernel (KDE) e Transformada de Box-Muller nativamente em Rust/WASM. Os experimentos compararam a base original (`entrada.csv`, com 44.023 registros) e amostras sintéticas de 40.000 pontos em três execuções independentes. O gerador em Rust demonstrou altíssima fidelidade estatística, validada pelo teste de Kolmogorov-Smirnov (p-valor de 0,1385 para temperatura e 0,8974 para umidade) e pelo desvio de correlação de Pearson de apenas 0,0033. Os resultados mostraram que o k NN isolado alcança 97,84% de redução de volume de dados (reduzindo a base para 40 KB), superando a combinação k NN+RLE (96,32%, ou 68 KB). Isso revela a ineficiência do RLE em alfabetos curtos de caractere único frente à variabilidade natural de alta frequência dos sensores físicos, fornecendo diretrizes de projeto cruciais para arquiteturas de IoT na névoa.

Palavras-chave: Computação em Névoa. Internet das Coisas (IoT). Agricultura Inteligente. Rust. WebAssembly. WasmEdge. Compressão de Dados.

Abstract

Smart agriculture stands as one of the primary frontiers for the Internet of Things (IoT), requiring continuous monitoring of environmental variables in remote areas. However, streaming large volumes of raw sensor data directly to the cloud over low-power, narrow-bandwidth channels (such as LoRaWAN) causes network congestion, latency, and rapid battery depletion. As a direct continuation and practical implementation of the theoretical research proposed by Ribeiro Junior et al. (JUNIOR et al., 2020), this work proposes and evaluates a fog computing ecosystem built with Rust and WebAssembly (WASM) to perform data filtering and compression at the network edge. Using a k -Nearest Neighbors classification algorithm (k NN, with $k = 3$) tailored to tomato agronomic status, the system maps continuous temperature and humidity readings into single-character discrete labels, which are compressed using Run Length Encoding (RLE). For validation, an offline stochastic data generator was developed natively in Rust/WASM using Kernel Density Estimation (KDE) and the Box-Muller transform. Experiments compared the original dataset (`entrada.csv`, 44,023 records) with synthetic samples of 40,000 points across three independent runs. The Rust generator achieved high statistical fidelity, validated by the Kolmogorov-Smirnov test (p-value of 0.1385 for temperature and 0.8974 for humidity) and a Pearson correlation deviation of just 0.0033. Results showed that standalone k NN achieves a 97.84% data reduction (shrinking the payload to 40 KB), outperforming the combined k NN+RLE approach (96.32%, or 68 KB). This highlights the inefficiency of RLE when applied to a single-character alphabet under high-frequency physical sensor fluctuations, providing critical design guidelines for fog-based IoT architectures.

Keywords: Fog Computing. Internet of Things (IoT). Smart Agriculture. Rust. WebAssembly. WasmEdge. Data Compression.

Lista de ilustrações

Figura 1 – Esquema lógico do pipeline: Sensor → Gateway LoRa → Processador (Névoa kNN+RLE) → Nuvem	24
Figura 2 – Curvas de contorno de densidade de probabilidade bidimensional . . .	33
Figura 3 – Correlogramas de Temperatura vs Umidade classificados por kNN (Round 1)	35
Figura 4 – Correlogramas de Temperatura vs Umidade classificados por kNN (Round 2)	36
Figura 5 – Comparação de Densidade Bidimensional Completa (Original vs Sintético)	37

Lista de tabelas

Tabela 1	– Disciplinas do BCC/UFABC e sua contribuição ao projeto	14
Tabela 2	– Tabela de treinamento e categorias da cultura de tomate	30
Tabela 3	– Detalhamento da partição dos dados em lotes no Experimento 1	38
Tabela 4	– Tamanhos finais após compactação kNN+RLE (Bytes)	39
Tabela 5	– Taxas de redução acumuladas (kNN+RLE) em relação ao JSON original (%)	39
Tabela 6	– Comparação de redução: kNN Puro vs kNN+RLE	40

Sumário

1	INTRODUÇÃO	11
1.1	PROBLEMA DE PESQUISA	11
1.2	OBJETIVOS	12
1.2.1	Objetivo Geral	12
1.2.2	Objetivos Específicos	12
1.3	JUSTIFICATIVA	12
1.4	DISCIPLINAS FORMADORAS DO PROJETO	13
1.5	ORGANIZAÇÃO DO TEXTO	14
2	REFERENCIAL TEÓRICO	15
2.1	Computação em Névoa (Fog Computing)	15
2.2	IoT-Cloud Continuum (IoTInuum)	15
2.3	Rust e WebAssembly (WASM)	15
2.3.1	Linguagem Rust	15
2.3.2	WebAssembly (WASM) e WASI	16
2.3.3	WasmEdge Runtime	16
2.4	Algoritmo dos k-Vizinhos Mais Próximos (kNN)	16
2.5	Compressão Run Length Encoding (RLE)	17
2.6	Geração Estocástica via KDE e Box-Muller	17
2.6.1	Estimativa de Densidade por Kernel (KDE)	17
2.6.2	Transformada de Box-Muller	18
2.7	Métodos de Validação Estatística	18
2.7.1	Teste de Kolmogorov-Smirnov (KS) de Duas Amostras	18
2.7.2	Coeficiente de Correlação de Pearson	20
3	REVISÃO DE LITERATURA	22
3.1	Trabalho de Base: Ribeiro Junior et al. (2020) - MetroAGriFor 2020	22
3.2	Avanços Introduzidos pelo Presente Projeto	22
4	DESENVOLVIMENTO E ARQUITETURA	24
4.1	Visão Geral da Arquitetura	24
4.2	Componentes do Código e Implementação	25
4.2.1	Dispositivo IoT (simulador)	25
4.2.2	Gateway/Relay LoRa (LoRa)	25
4.2.3	Processador na Névoa (processador)	25
4.2.4	Receptor na Nuvem (receiver)	26

4.2.5	Scripts de Validação e Análise em Python (gerador-de-dados)	26
4.3	Fluxos de Execução do Processador	26
4.3.1	Modo Normal (Online / Serviço HTTP)	27
4.3.2	Modo Lote (Offline / Batch Mode)	27
4.3.3	Modo de Geração de Dados Sintéticos	27
4.4	Outputs e Logs de Execução dos Componentes	27
4.4.1	Logs do Modo Normal (Online)	27
4.4.2	Logs do Modo Lote (Batch Offline)	28
5	METODOLOGIA E CONFIGURAÇÃO EXPERIMENTAL	30
5.1	Ambiente de Execução Experimental	30
5.2	O Dataset e o Modelo do Tomateiro	30
5.3	Configuração dos Experimentos de Compressão	31
5.4	Planilha de Métricas de Validação	31
6	RESULTADOS E DISCUSSÃO	32
6.1	Validação Estatística dos Dados Sintéticos	32
6.2	Análise Visual das Curvas de Densidade e Distribuição	32
6.3	Resultados da Compressão de Dados nos Experimentos	38
6.3.1	Custo de Serialização JSON e o Overhead de Colchetes	38
6.3.2	Efeito de Borda e o Lote Ideal	38
6.3.3	Consistência entre Execuções Independentes	39
6.4	Comparação kNN Puro vs kNN+RLE	40
6.4.1	Discussão sobre a Ineficiência do RLE	40
7	CONCLUSÃO	42
	REFERÊNCIAS	43
	APÊNDICE A – ESTRUTURA DO PROJETO DE SENSORES E NÉVOA	44
	APÊNDICE B – MODELO DOS DADOS SERIALIZADOS (JSON)	45
	APÊNDICE C – COMANDOS DE LINHA DE COMANDO (CLI) E ROTEIRO DE EXECUÇÃO	46
C.0.1	Compilação de cada Componente para WebAssembly	46
C.0.2	Modo Normal (Fluxo Online de Rede)	46
C.0.3	Modo Lote (Offline / Batch Mode)	47

1 INTRODUÇÃO

A Internet das Coisas (IoT) revolucionou a agricultura de precisão, permitindo que sensores coletem continuamente variáveis ambientais como temperatura, umidade, luminosidade e umidade do solo. Na agricultura inteligente, o monitoramento em tempo real dessas grandezas é vital para otimizar a produtividade e a saúde das plantações. No entanto, a arquitetura tradicional que centraliza a coleta de dados e os envia diretamente à nuvem enfrenta graves gargalos operacionais.

Sensores implantados no campo operam sob fortes restrições de energia e dependem de redes de comunicação sem fio de baixa potência e longo alcance (LPWAN), como LoRaWAN, que operam com taxas de transmissão extremamente baixas (tipicamente entre 292 bps e 50 kbps) e limitações rígidas de ciclo de trabalho (*duty cycle*) (ADELANTADO et al., 2017). O envio ininterrupto de dados brutos gera alto consumo de bateria nos nós sensores e congestionamento de rede no gateway.

Nesse cenário, a computação em névoa (*fog computing*) atua como uma camada intermediária entre os dispositivos sensores de borda e os servidores em nuvem. Ao transferir capacidade computacional de processamento e tomada de decisão para os gateways locais, torna-se possível aplicar algoritmos de filtragem de dados e compressão antes da transmissão WAN. Desta forma, envia-se apenas informação relevante para a nuvem, economizando largura de banda e prolongando a vida útil das baterias dos nós de borda.

Este trabalho apresenta-se como uma continuação direta e evolução prática da pesquisa pioneira desenvolvida por Ribeiro Junior et al. (JUNIOR et al., 2020), transpondo e testando seus modelos teóricos em uma arquitetura executável e de alto desempenho na névoa.

1.1 PROBLEMA DE PESQUISA

A filtragem de dados na névoa exige um ambiente de execução leve, portátil e seguro para rodar códigos de terceiros nos gateways de borda. Máquinas virtuais pesadas ou contêineres tradicionais (como Docker) demandam muitos recursos computacionais, tornando-se inviáveis para os hardwares limitados comuns na névoa. Além disso, linguagens tradicionais de script (como Python) carecem do desempenho e eficiência necessários, enquanto linguagens compiladas nativas (como C/C++) apresentam riscos severos de segurança de memória.

A pesquisa original de Ribeiro Junior et al. (JUNIOR et al., 2020) propôs o uso de k -Vizinhos Mais Próximos (k NN) e Run Length Encoding (RLE) em gateways para reduzir

a taxa de transmissão em aplicações agrícolas. Contudo, a viabilização prática desse modelo em sistemas de produção exige responder à seguinte questão: *Como implementar e validar um ecossistema seguro, portátil e de alto desempenho para filtragem e compressão de dados agrícolas na borda, utilizando modernas tecnologias de compilação como Rust e WebAssembly, e como garantir a estabilidade e a validade estatística desse processamento em cenários off-line?*

1.2 OBJETIVOS

1.2.1 Objetivo Geral

Propor, implementar e validar um framework fim-a-fim de computação em névoa que realiza filtragem de dados agrônômicos por meio de classificação k NN e compressão RLE, compilado para WebAssembly (WASM) a partir de Rust e executado no ambiente de alto desempenho WasmEdge.

1.2.2 Objetivos Específicos

- Implementar o classificador k NN ($k = 3$) para classificar dados de sensores em 11 classes de sanidade do tomateiro;
- Desenvolver o codificador RLE em Rust para comprimir sequências de classes resultantes do k NN;
- Desenvolver um módulo de simulação estocástica de dados nativo em Rust que implementa Estimativa de Densidade por Kernel (KDE) e Transformada de Box-Muller para ambiente WASM/WASI;
- Validar estatisticamente a fidelidade do gerador estocástico contra a base de dados reais de sensores (`entrada.csv`) por meio de testes de Kolmogorov-Smirnov (KS-test) e correlação de Pearson;
- Avaliar comparativamente a eficiência de compressão obtida com k NN isolado e k NN+RLE sob diferentes tamanhos de lote de processamento.

1.3 JUSTIFICATIVA

A transposição de algoritmos de processamento de dados para a névoa usando a linguagem Rust e o ambiente WebAssembly justifica-se por razões tecnológicas e práticas fundamentais:

Desempenho e Segurança: Rust garante segurança de memória sem a necessidade de um coletor de lixo (*garbage collector*), entregando eficiência equivalente a C/C++ sem o risco de falhas catastróficas (*buffer overflows*, vazamento de memória).

Otimização com WebAssembly e WasmEdge: Rust funciona de maneira ideal ao ser compilado para alvos WebAssembly (WASM), gerando bytecode portátil de alta segurança executado quase à velocidade nativa. A execução sob o runtime **WasmEdge** expande as limitações tradicionais do padrão WASI ao fornecer suporte nativo para soquetes de rede e chamadas HTTP de forma direta de dentro do sandbox isolado. Isso viabiliza que o gateway de névoa faça o upload dos pacotes de dados classificados e comprimidos diretamente para os servidores de nuvem de forma assíncrona, descartando a dependência de processos nativos adicionais e garantindo isolamento estrito de segurança.

Economia de Infraestrutura: A redução sistemática do tamanho dos pacotes e da frequência de envio viabiliza na prática a implantação de um número maior de sensores sob a mesma infraestrutura LoRaWAN existente.

Validação Estatística com Dados Sintéticos: A capacidade de gerar dados sintéticos estatisticamente idênticos permite testar de forma robusta e exaustiva novos algoritmos e configurações de rede off-line, sem a necessidade de dispendiosas campanhas de campo para coleta contínua.

1.4 DISCIPLINAS FORMADORAS DO PROJETO

O desenvolvimento do projeto utilizou conceitos de diversas áreas de conhecimento da Ciência da Computação da UFABC, conforme detalhado na Tabela 1.

Tabela 1 – Disciplinas do BCC/UFABC e sua contribuição ao projeto

Disciplina	Código	Contribuição ao Projeto
Inteligência Artificial	MCTA014-15	Fundamentação de classificadores supervisionados para a concepção e parametrização do algoritmo k NN.
Sistemas Distribuídos	MCTA025-13	Comunicação cliente-servidor e arquitetura de dados IoT na passagem de dados de sensores do Thing para a Névoa e para a Nuvem.
Redes de Computadores	MCTA024-13	Conhecimentos sobre protocolos de comunicação de baixo consumo e restrições de transmissão em canais sem fio de longa distância.
Compiladores	MCTA009-17	Compreensão da geração de representação intermediária e otimização de código necessária para compilar código Rust em bytecode WebAssembly.
Algoritmos e Estruturas de Dados II	MCTA002-17	Estruturas de representação na memória para busca de vizinhos mais próximos e indexação de buffer de dados temporais para compressão RLE.

Fonte: O Autor (2026)

1.5 ORGANIZAÇÃO DO TEXTO

Este trabalho está estruturado da seguinte forma: o Capítulo 2 apresenta o referencial teórico cobrindo as tecnologias Rust, WebAssembly, k NN, RLE e o gerador estocástico; o Capítulo 3 detalha a revisão de literatura com foco no artigo MetroAGriFor 2020; o Capítulo 4 descreve a arquitetura e implementação dos componentes; o Capítulo 5 apresenta a metodologia de teste e o plano de validação; o Capítulo 6 discute os resultados obtidos, acompanhados das análises estatísticas e dos gráficos; e o Capítulo 7 resume as principais conclusões e propostas para trabalhos futuros.

2 REFERENCIAL TEÓRICO

2.1 Computação em Névoa (Fog Computing)

A computação em névoa estende o paradigma da computação em nuvem para a borda da rede de modo a mitigar a latência e o consumo de banda. Em contraste com a nuvem, a névoa oferece recursos descentralizados com localização geográfica distribuída e proximidade física com os dispositivos IoT. Em sistemas agrícolas, os gateways locais (como Raspberry Pi ou gateways industriais) atuam como nós de névoa, realizando o processamento preliminar de leituras de sensores antes de encaminhá-las aos servidores de aplicação remotos.

2.2 IoT-Cloud Continuum (IoTinuum)

O conceito de contínuo IoT-Nuvem (*IoT-Cloud Continuum*), frequentemente denominado de *IoTinuum*, representa a integração e a orquestração unificada de recursos computacionais distribuídos ao longo de toda a infraestrutura física e de rede, estendendo-se desde os dispositivos de borda mais básicos (Things/Sensores) até os datacenters de nuvem de alta capacidade, passando pelas camadas intermediárias da névoa.

Em vez de tratar a névoa e a nuvem como silos de computação isolados, o *IoTinuum* propõe um ambiente de execução contínuo no qual as tarefas de processamento de dados, filtragem e tomada de decisão são dinamicamente alocadas e executadas no ponto mais adequado da rede. No monitoramento agrícola inteligente, o contínuo permite balancear o consumo de energia dos nós sensores de campo com a largura de banda disponível nos gateways locais de névoa e a capacidade de processamento analítico histórico na nuvem, otimizando o fluxo de dados de ponta a ponta (KAMIENSKI et al., 2018).

2.3 Rust e WebAssembly (WASM)

2.3.1 Linguagem Rust

Rust é uma linguagem de programação focada em segurança, velocidade e concorrência (MATSAKIS; II, 2014). Seu sistema de tipos e o conceito de posse (*ownership*) com checagem de tempo de vida (*borrow checker*) eliminam erros comuns de gerência de memória em tempo de compilação, sem depender de coleta de lixo. Isso garante um consumo de memória previsível e baixo, ideal para os dispositivos de borda.

2.3.2 WebAssembly (WASM) e WASI

WebAssembly é um formato de instrução binária projetado para ser executado de forma portátil em uma máquina virtual baseada em pilha (HAAS et al., 2017). Embora originalmente concebido para navegadores web, o WASM expandiu-se para o lado do servidor por meio da *WebAssembly System Interface* (WASI), que padroniza o acesso a recursos do sistema operacional (como arquivos, rede e relógio). O bytecode WASM é executado sob isolamento completo (*sandbox*), protegendo o gateway hospedeiro contra códigos maliciosos ou falhas de execução.

2.3.3 WasmEdge Runtime

WasmEdge é um interpretador e compilador JIT/AOT de WebAssembly de alto desempenho otimizado para cenários de computação de borda, névoa e microsserviços (WasmEdge Runtime, 2023). Desenvolvido sob a tutela da Cloud Native Computing Foundation (CNCF), ele suporta a especificação WASI e oferece extensões para acelerar inferência de redes neurais, tornando-o o runtime ideal para executar pipelines de processamento estocástico e classificação local.

2.4 Algoritmo dos k-Vizinhos Mais Próximos (kNN)

O k NN é um algoritmo de aprendizado supervisionado não-paramétrico. O princípio consiste em classificar um novo ponto no espaço tridimensional ou bidimensional a partir do voto majoritário dos seus k vizinhos mais próximos no conjunto de treino.

Para que variáveis físicas com ordens de grandeza distintas (como temperatura em °C e umidade em %) tenham o mesmo peso no cálculo das distâncias, aplica-se a normalização Min-Max dos dados para o intervalo $[0, 1]$ com base nos limites x_{min} e x_{max} obtidos a priori:

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}} \quad (2.1)$$

A distância Euclidiana entre um vetor de leitura de sensor $P = (T_p, H_p)$ e um ponto do conjunto de treinamento $Q = (T_q, H_q)$ no espaço normalizado bidimensional é dada por:

$$d(P, Q) = \sqrt{(T_{p,norm} - T_{q,norm})^2 + (H_{p,norm} - H_{q,norm})^2} \quad (2.2)$$

O algoritmo seleciona os k registros de treinamento com as menores distâncias d e realiza uma votação majoritária para determinar a classe agrônômica a ser associada à nova leitura física.

2.5 Compressão Run Length Encoding (RLE)

A codificação de comprimento de corrida (RLE) é um método simples de compressão de dados sem perdas (*lossless*), ideal para sequências com repetições frequentes de símbolos idênticos. O algoritmo substitui sequências contíguas de um mesmo caractere por um par constituído pelo número de ocorrências e o próprio caractere (exemplo: a cadeia **AAAAABBB** é representada por **5A3B**).

Em dados agrícolas classificados por kNN, a redundância temporal é elevada, uma vez que a temperatura e a umidade mudam lentamente, gerando longas corridas consecutivas do mesmo status agrônômico (por exemplo, várias horas consecutivas no estado "Optimal").

2.6 Geração Estocástica via KDE e Box-Muller

No contexto deste projeto, a Estimativa de Densidade por Kernel (KDE) e a Transformada de Box-Muller foram utilizadas para conceber e implementar um **gerador estocástico off-line de dados de sensores** integrado diretamente no processador em Rust. Em cenários de IoT agrícola, a realização de campanhas contínuas de campo para coleta física de sensores pode ser financeiramente inviável ou limitada no tempo. Com a incorporação do gerador KDE, o gateway de névoa é capaz de sintetizar grandes conjuntos de dados (como as séries de 40.000 pontos avaliadas nos experimentos) estatisticamente consistentes com as leituras físicas originais (**entrada.csv**). A transformada de Box-Muller é o mecanismo que viabiliza essa geração estocástica de forma autônoma de dentro do *sandbox* isolado do WebAssembly (WASI), onde os geradores de números aleatórios nativos do sistema operacional hospedeiro são inacessíveis ou severamente restritos. Essa emulação de alta fidelidade permite realizar baterias de testes experimentais off-line, avaliar o comportamento dinâmico de rede e verificar a eficiência dos algoritmos de classificação e compressão sob cargas realistas de sensores sem a necessidade de acoplamento físico com o hardware no gateway durante fases de validação.

2.6.1 Estimativa de Densidade por Kernel (KDE)

O KDE é um método não-paramétrico para estimar a função de densidade de probabilidade (PDF) de uma variável aleatória contínua multivariada (SILVERMAN, 1986). Dada uma amostra real $\{X_1, X_2, \dots, X_n\}$ extraída da base física, o estimador de densidade por kernel em d dimensões é definido como:

$$\hat{f}(x) = \frac{1}{nh^d} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right) \quad (2.3)$$

onde $h > 0$ é a largura de banda (*bandwidth*) e $K(u)$ é a função de kernel gaussiano normal multivariado.

Para gerar um novo ponto sintético $x_{sint} = (T_{sint}, H_{sint})$ a partir do KDE:

1. Seleciona-se uniformemente ao acaso um ponto base $X_i = (T_i, H_i)$ do conjunto de dados reais (`entrada.csv`);
2. Adiciona-se ruído normal independente de média 0 e desvio padrão igual à largura de banda $h = 0.5$ em cada dimensão:

$$T_{sint} = T_i + Z_1 \cdot h \quad (2.4)$$

$$H_{sint} = H_i + Z_2 \cdot h \quad (2.5)$$

onde $Z_1, Z_2 \sim \mathcal{N}(0, 1)$ são variáveis aleatórias normais padrão independentes.

2.6.2 Transformada de Box-Muller

A geração de variáveis normais padrão $Z \sim \mathcal{N}(0, 1)$ em Rust dentro do sandbox WebAssembly (WASI) requer um algoritmo autossuficiente e determinístico. A transformada de Box-Muller (BOX; MULLER, 1958) converte duas variáveis pseudo-aleatórias mutuamente independentes distribuídas uniformemente no intervalo aberto $(0, 1]$, denotadas por U_1 e U_2 , em duas variáveis normais padrão independentes:

$$Z_0 = \sqrt{-2 \ln(U_1)} \cdot \cos(2\pi U_2) \quad (2.6)$$

$$Z_1 = \sqrt{-2 \ln(U_1)} \cdot \sin(2\pi U_2) \quad (2.7)$$

Esse método permite gerar o ruído estocástico gaussiano do KDE de forma exata e rápida sem recorrer a bibliotecas de sistema operacional ausentes no sandbox do WASM.

2.7 Métodos de Validação Estatística

Para validar cientificamente a fidelidade dos dados sintéticos gerados pelo processador em relação às leituras originais dos sensores físicos, empregam-se duas abordagens estatísticas complementares: o teste de Kolmogorov-Smirnov (KS) e o coeficiente de correlação de Pearson.

2.7.1 Teste de Kolmogorov-Smirnov (KS) de Duas Amostras

O teste de Kolmogorov-Smirnov (KS) de duas amostras é um teste estatístico não-paramétrico utilizado para comparar se duas distribuições empíricas contínuas provêm da mesma distribuição de probabilidade populacional contínua (MASSEY, 1951). A principal vantagem deste teste é que ele não assume nenhuma distribuição a priori (como a normalidade) para as variáveis analisadas, sendo amplamente aplicável a qualquer tipo de distribuição contínua.

Dadas duas amostras independentes $X = \{X_1, X_2, \dots, X_n\}$ e $Y = \{Y_1, Y_2, \dots, Y_m\}$ de tamanhos n e m , suas funções de distribuição acumulada empírica (ECDF - *Empirical Cumulative Distribution Function*) são definidas, respectivamente, por:

$$F_{1,n}(t) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}_{X_i \leq t} \quad (2.8)$$

$$F_{2,m}(t) = \frac{1}{m} \sum_{j=1}^m \mathbb{I}_{Y_j \leq t} \quad (2.9)$$

onde $\mathbb{I}_A$ é a função indicadora, assumindo o valor 1 se a condição A for verdadeira e 0 caso contrário.

A estatística de teste de Kolmogorov-Smirnov, denotada por D , quantifica a distância máxima vertical absoluta entre as duas ECDFs:

$$D = \sup_t |F_{1,n}(t) - F_{2,m}(t)| \quad (2.10)$$

Geometricamente, a estatística D representa o supremo da diferença absoluta entre as trajetórias das duas funções acumuladas empíricas. Devido a essa definição, o teste KS é sensível a qualquer diferença de comportamento entre as duas distribuições, incluindo desvios de localização (média), dispersão (variância), assimetria (*skewness*) ou curtose.

A hipótese nula (H_0) assume que ambas as amostras são extraídas da mesma distribuição populacional contínua ($F_1(t) = F_2(t)$ para todo t), enquanto a hipótese alternativa (H_1) assume que as distribuições são distintas. Rejeita-se H_0 a um nível de significância α se a estatística de teste calculada D for superior a um valor crítico limite d_α . Para amostras de tamanho suficientemente grande ($n, m > 30$), o valor crítico aproximado pode ser determinado assintoticamente por:

$$d_\alpha = c(\alpha) \sqrt{\frac{n+m}{n \cdot m}} \quad (2.11)$$

onde o coeficiente $c(\alpha)$ é derivado da distribuição limite de Kolmogorov. Para os níveis de significância usuais de $\alpha = 0,10$, $\alpha = 0,05$ e $\alpha = 0,01$, os valores de $c(\alpha)$ são dados aproximadamente por 1,22, 1,36 e 1,63, respectivamente.

O p-valor correspondente expressa a probabilidade de obter uma estatística de teste pelo menos tão extrema quanto a estatística calculada sob a suposição de que a hipótese nula seja verdadeira. Em termos práticos de teste, se o p-valor for maior que o nível de significância adotado ($\alpha = 0,05$), não se rejeita a hipótese nula H_0 . No contexto da validação do simulador estocástico desenvolvido em Rust, isso implica que as distribuições geradas sinteticamente e as distribuições físicas reais coletadas são estatisticamente indistinguíveis.

Uma premissa teórica importante do teste KS é que a variável analisada seja estritamente contínua, o que garante a inexistência de empates estatísticos (valores idênticos) nas amostras. Embora dados digitalizados de sensores (como temperatura e umidade com precisão limitada de casas decimais) apresentem empates pontuais, o teste permanece aplicável, atuando de maneira ligeiramente mais conservadora, o que minimiza a probabilidade de se cometer um erro do Tipo I (rejeitar falsamente a hipótese nula de igualdade).

2.7.2 Coeficiente de Correlação de Pearson

O coeficiente de correlação linear de Pearson (r) é uma medida estatística que quantifica a intensidade e a direção da associação linear entre duas variáveis quantitativas contínuas (no escopo deste trabalho, as leituras de temperatura T e umidade H) (PEARSON, 1895).

Matematicamente, o coeficiente r é expresso como a razão entre a covariância amostral das duas variáveis e o produto de seus respectivos desvios padrão amostrais. Dado um conjunto de n pares de observações $\{(T_1, H_1), (T_2, H_2), \dots, (T_n, H_n)\}$, o cálculo é formulado como:

$$r = \frac{s_{TH}}{s_T \cdot s_H} = \frac{\sum_{i=1}^n (T_i - \bar{T})(H_i - \bar{H})}{\sqrt{\sum_{i=1}^n (T_i - \bar{T})^2 \sum_{i=1}^n (H_i - \bar{H})^2}} \quad (2.12)$$

onde:

- s_{TH} representa a covariância amostral entre a temperatura e a umidade:

$$s_{TH} = \frac{1}{n-1} \sum_{i=1}^n (T_i - \bar{T})(H_i - \bar{H}) \quad (2.13)$$

- s_T e s_H representam os desvios padrão amostrais das respectivas variáveis:

$$s_T = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (T_i - \bar{T})^2} \quad \text{e} \quad s_H = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (H_i - \bar{H})^2} \quad (2.14)$$

- $\bar{T}$ e $\bar{H}$ correspondem às médias amostrais calculadas para a amostra.

O coeficiente de correlação de Pearson assume valores estritamente no intervalo $[-1, 1]$, fornecendo as seguintes interpretações:

- $r = 1$: indica uma relação linear positiva perfeita; as duas variáveis variam proporcionalmente no mesmo sentido.
- $r = -1$: indica uma relação linear negativa (inversa) perfeita; quando uma variável aumenta, a outra diminui de maneira estritamente proporcional.
- $r = 0$: indica a total ausência de associação linear entre as variáveis, embora relações não-lineares complexas ainda possam existir.

Para a caracterização qualitativa da força da associação linear entre as variáveis, costuma-se adotar faixas de classificação em módulo ($|r|$):

- $0,00 \leq |r| < 0,30$: associação linear muito fraca ou desprezível;
- $0,30 \leq |r| < 0,50$: associação linear de intensidade moderada-baixa;
- $0,50 \leq |r| < 0,70$: associação linear de intensidade moderada-alta;
- $0,70 \leq |r| \leq 1,00$: associação linear forte a muito forte.

Além disso, o quadrado do coeficiente de correlação ($R^2 = r^2$) representa o coeficiente de determinação, indicando a proporção de variância em uma variável que é explicada ou compartilhada pelo modelo linear associado à outra variável.

Para a validade da utilização do coeficiente de Pearson como indicador estatístico de interdependência física, deve-se assumir a linearidade da relação, a ausência de valores atípicos (*outliers*) que possam distorcer a média aritmética e a covariância amostral, e, opcionalmente para testes de significância inferencial sobre o coeficiente populacional, a distribuição normal bivariada das variáveis.

Na agricultura inteligente, as variáveis climáticas de temperatura e umidade relativa do ar guardam uma relação termodinâmica intrínseca e fortemente inversa: conforme a temperatura do ar se eleva, a umidade relativa do ar tende a diminuir de forma expressiva. Comparar o desvio absoluto entre a correlação da base original (r_{orig}) e a correlação da base simulada (r_{rust}), dado por $|r_{orig} - r_{rust}|$, é uma métrica científica crítica para validar se a modelagem conjunta multivariada baseada em KDE em Rust foi capaz de preservar essa lei física da natureza no ecossistema sintético.

3 REVISÃO DE LITERATURA

3.1 Trabalho de Base: Ribeiro Junior et al. (2020) - MetroAGriFor 2020

Este projeto baseia-se diretamente na metodologia proposta por Ribeiro Junior et al. (JUNIOR et al., 2020), intitulada *"A Nearest Neighbors based Data Filter for Fog Computing in IoT Smart Agriculture"*. Aquele artigo estabeleceu as bases teóricas de um filtro de dados inteligente instalado em gateways de névoa locais.

No trabalho original, o filtro opera sobre sensores de temperatura e umidade aplicados à cultura de tomateiro. Para tal, as condições da planta são categorizadas de acordo com parâmetros agronômicos de estresse hídrico e térmico, gerando dados discretos que representam os estados de "Optimal", "Marginal", "Upper Fail", entre outros. O classificador k NN em nível de gateway é encarregado de mapear as variáveis físicas contínuas para essas classes discretas.

A proposta de Ribeiro Junior et al. demonstrou que, ao invés de transmitir as leituras flutuantes originais com alta frequência para a nuvem, a transmissão de sequências compactas de classes reduz sensivelmente o payload do protocolo de transporte (como MQTT ou HTTP sobre redes de satélite ou LoRa). A aplicação de compressão de corrida RLE sobre a cadeia de símbolos gerada pelo k NN estende essa redução ao compactar repetições temporais contíguas.

3.2 Avanços Introduzidos pelo Presente Projeto

Embora cientificamente elegante, o projeto original de Ribeiro Junior et al. (JUNIOR et al., 2020) foi concebido de forma puramente teórica e avaliado localmente via scripts de simulação offline (MATLAB/Python). O presente trabalho promove os seguintes avanços metodológicos e de engenharia de software:

1. **Mudança de Tecnologia:** Migração completa dos algoritmos de classificação k NN e codificação RLE para código Rust compilado para alvos WebAssembly (`wasm32-wasi`). Isso garante que a filtragem possa ser implantada de forma leve e segura em gateways reais sob o runtime WasmEdge;
2. **Concepção do Modo Offline com Geração KDE:** Implementação de um gerador estocástico nativo em Rust que opera sob as restrições WASI. Isso permite aos operadores de gateways emular dados sintéticos com base em um arquivo original sem a necessidade de manter o sensor físico acoplado durante fases de calibração;

3. **Avaliação Célula de Lote Estrita:** Teste do impacto prático de diferentes limites temporais de buffers (de 6 a 20.000 pacotes) para analisar as características reais de latência e ganho de compressão do RLE em escala temporal de produção.

4 DESENVOLVIMENTO E ARQUITETURA

4.1 Visão Geral da Arquitetura

O ecossistema implementado divide-se em quatro componentes principais distribuídos de forma a simular um ambiente de IoT real:




Figura 1 – Esquema lógico do pipeline: Sensor → Gateway LoRa → Processador (Névoa kNN+RLE) → Nuvem

Fonte: O Autor (2026)

1. **Dispositivo IoT (Thing/Simulador):** Simula os nós sensores de campo. Ele lê dados brutos do ambiente (ou dados sintéticos KDE) e transmite via protocolo local

para o gateway;

2. **Gateway/Relay LoRa (LoRa)**: Atua como uma ponte de comunicação de rede, retransmitindo e roteando os pacotes HTTP/JSON entre o dispositivo IoT e o processador local na névoa;
3. **Processador na Névoa (processador)**: Executa o runtime WasmEdge. Ele lê as variáveis físicas do buffer de entrada, normaliza os valores, classifica cada ponto pelo kNN ($k = 3$) e codifica sequencialmente via RLE, retransmitindo a carga compactada;
4. **Cloud Receiver (Nuvem)**: Recebe os dados processados e comprimidos do gateway/processador, realiza a descompressão e armazena-os na base persistente para visualização do usuário.

4.2 Componentes do Código e Implementação

A arquitetura de software do projeto foi desenvolvida utilizando a linguagem Rust, visando alto desempenho, segurança de memória e facilidade de portabilidade. O ecossistema é composto por quatro programas principais localizados nos diretórios do projeto:

4.2.1 Dispositivo IoT (simulador)

O módulo `simulador` emula a coleta física dos sensores de temperatura e umidade da cultura de tomateiro. Ele é configurado para realizar requisições HTTP do tipo `POST` para o gateway de névoa, enviando a leitura no formato JSON.

4.2.2 Gateway/Relay LoRa (LoRa)

O módulo `LoRa` atua como o gateway/relay intermediário no pipeline de comunicação. Ele simula a interface de recepção e envio sem fio LPWAN de forma simplificada em nível de aplicação, atuando como um proxy retransmissor HTTP/JSON leve. Ele escuta conexões locais (porta padrão 8080) e aceita requisições do tipo `POST` nas rotas `/inserir` e `/receber`, retransmitindo os payloads para os respectivos componentes de processamento ou recepção.

4.2.3 Processador na Névoa (processador)

O módulo `processador` é o núcleo do ecossistema. Ele é compilado para WebAssembly (`wasm32-wasip1`) e executado sobre o runtime leve `WasmEdge`. Ele implementa:

- A leitura e parsing das estruturas JSON correspondentes aos sensores;

- A base de dados de treinamento estática de 11 faixas de saúde do tomateiro;
- A normalização Min-Max e o algoritmo de busca e classificação de vizinhos k NN ($k = 3$);
- O algoritmo de compressão Run-Length Encoding (RLE) temporal sobre a sequência de caracteres obtidos;
- Um gerador estocástico multivariado de dados sintéticos via KDE com ruído gaussiano (Box-Muller).

4.2.4 Receptor na Nuvem (receiver)

O módulo `receiver` atua como o servidor na nuvem que recebe as strings compactadas do processador, simula a descompressão dos dados de controle e realiza a escrita dos logs de recepção em um arquivo persistente (`monitoramento.txt`) para auditoria e exibição.

4.2.5 Scripts de Validação e Análise em Python (gerador-de-dados)

Além dos módulos em Rust executados no contínuo de IoT, o projeto conta com um conjunto de scripts utilitários desenvolvidos em Python (na pasta `gerador-de-dados/`) com o objetivo de realizar análises estatísticas de suporte e validação gráfica:

- `gerar_graficos_artigo.py`: Este script é responsável pela geração das representações visuais equivalentes às Figuras 3 e 4 do artigo original de Ribeiro Junior et al. (JUNIOR et al., 2020). Ele carrega as séries temporais (tanto da base real quanto da base sintética gerada em Rust), classifica-as usando a mesma heurística normalizada do k NN, e gera as curvas de contorno de densidade conjunta e os correlogramas de dispersão de classes. Serve como ferramenta de validação visual e aderência topológica;
- `validar_dados_rust.py`: Atua como a suíte de testes estatísticos formais do gerador estocástico. Ele lê o arquivo original `entrada.csv` e o arquivo de dados sintéticos gerados pelo processador Rust (`dados_sinteticos_gerados_rust.csv`), computa e imprime os p-valores do teste Kolmogorov-Smirnov (KS) de duas amostras para cada variável (temperatura e umidade), calcula os coeficientes de correlação linear de Pearson de ambas as distribuições para verificar a integridade da interdependência física das variáveis e gera gráficos comparativos de dispersão e histogramas.

4.3 Fluxos de Execução do Processador

O processador foi projetado com suporte a dois fluxos operacionais principais que atendem a cenários de rede distintos:

4.3.1 Modo Normal (Online / Serviço HTTP)

Neste modo, o processador atua como um servidor HTTP ativo escutando por requisições de sensores em tempo real. Ele expõe a rota `POST /inserir` para coletar leituras contínuas. Em segundo plano, uma rotina assíncrona (*background thread*) rodando a cada 30 segundos agrupa os dados acumulados, executa a compactação RLE, envia os dados comprimidos para o receptor na nuvem (`POST /receber`) e limpa o buffer local para o próximo ciclo de monitoramento.

4.3.2 Modo Lote (Offline / Batch Mode)

Ativado pela passagem do argumento posicional `batch` na CLI, este fluxo destina-se ao processamento local de arquivos de sensores para campanhas offline e avaliações científicas de longa duração. Ele lê diretamente um arquivo CSV de entrada (ex.: `entrada.csv`), divide os dados em lotes com base em um tamanho de pacote configurável (via flag `-tamanho-pacote`), executa a classificação kNN e compressão RLE para cada lote, exporta estatísticas agregadas completas no formato JSON (`estatisticas_compressao.json`) e finaliza a execução.

4.3.3 Modo de Geração de Dados Sintéticos

Quando a flag `-synthetic` (ou `-sintetico`) é especificada em conjunto com o modo `batch`, o processador executa a amostragem baseada na Estimativa de Densidade por Kernel (KDE) a partir do CSV de referência. Ele gera 40.000 registros sintéticos de temperatura e umidade aplicando ruído estocástico gaussiano via Box-Muller, salva a base sintética resultante em `dados_sinteticos_gerados_rust.csv` e processa a cadeia simulada em lote sob as mesmas regras do Modo Lote offline.

4.4 Outputs e Logs de Execução dos Componentes

Para fins de validação operacional e documentação das saídas técnicas, os logs a seguir demonstram a inicialização e o tráfego de mensagens em tempo de execução de cada componente do ecossistema.

4.4.1 Logs do Modo Normal (Online)

O script de inicialização inicia o receptor de nuvem na porta 8082, seguido pelo processador do gateway na porta 8081 e pelo simulador de sensores. O log a seguir detalha a inicialização do processador na névoa:

```
=====
[INFO] Filtro rodando na porta 8081
```

```
[INFO] Ambiente: Fog
[INFO] Receiver alvo: http://localhost:8082/receber
[INFO] Ciclo de envio: 30 segundos
=====
Endpoints:
  POST /inserir      - Recebe dados dos sensores
  GET  /classificados - Lista dados classificados
  GET  /rle          - Aplica RLE e retorna compressao
  GET  /estatisticas - Estatisticas dos dados
  POST /reset        - Limpa todos os dados
=====
```

Listing 4.1 – Log de inicialização do Processador na Névoa

Durante a operação estável, conforme o simulador transmite dados de leitura, o processador imprime as operações de empacotamento e encaminhamento para a nuvem no final do timer de 30 segundos, conforme listado abaixo:

```
Requisicao recebida: POST /inserir
Requisicao recebida: POST /inserir
[SEND] Fog [Fog]: Enviando dados RLE para o Receiver...
[SUCCESS] Dados enviados com sucesso. Limpando armazenamento local...
[WAIT] Fog [Fog]: Sem dados para enviar neste ciclo.
```

Listing 4.2 – Logs de recebimento e envio do gateway de névoa no Modo Normal

O receptor de nuvem (receiver) exibe os logs de recepção e a taxa de redução dos dados empacotados pelo gateway, conforme o log a seguir:

```
=====
[INFO] Receiver (Cloud) rodando na porta 8082
[INFO] Ambiente: Cloud
[INFO] Arquivo de log: monitoramento.txt
=====
[RECV] Receiver: Recebendo pacotes RLE...
[SAVE] Salvando string comprimida: 2406P1G
[STATS] Reducao: 96.32%
```

Listing 4.3 – Log de recepção do Receiver na Nuvem

4.4.2 Logs do Modo Lote (Batch Offline)

A execução offline do processamento em lote com a geração de dados sintéticos gera logs que detalham o carregamento da base, a amostragem probabilística e as taxas globais de redução calculadas. O output gerado pela execução do comando `wsl bash -l start_all.sh 4 -synthetic` é listado abaixo:

```
=====
```

```
[START] Build concluido. Iniciando Modo: 4
=====
Configuracao 4: Processamento Offline em Lote (Batch Mode)
[INFO] Carregando dados base de entrada.csv...
[SUCCESS] 44023 registros carregados do CSV base.
[GEN] Gerando 40000 registros sinteticos usando KDE (bandwidth = 0.5)...
[SAVE] Salvando dados sinteticos gerados em '
      dados_sinteticos_gerados_rust.csv'...
[SUCCESS] Arquivo 'dados_sinteticos_gerados_rust.csv' salvo com sucesso.
=====
[STATS] Relatorio de Processamento em Lote Gerado!
[FILE] Arquivo salvo em: estatisticas_compressao.json
[TOTAL] Total de registros processados: 40000
[SIZE] Tamanho original acumulado: 1856634 bytes
[kNN] Tamanho apos kNN: 40000 bytes (Reducao: 97.85%)
[RLE] Tamanho apos kNN+RLE: 69812 bytes (Reducao: 96.24%)
=====
```

Listing 4.4 – Log de execução do Processador no Modo Lote com Dados Sintéticos

Estes logs registram a execução exata dos experimentos de compactação utilizados para as discussões estatísticas e de engenharia de software presentes na seção de resultados.

5 METODOLOGIA E CONFIGURAÇÃO EXPERIMENTAL

5.1 Ambiente de Execução Experimental

Para garantir a reprodutibilidade de todas as avaliações de desempenho do ecossistema, os testes operacionais (envolvendo os quatro módulos Rust desenvolvidos) e as análises estatísticas em Python foram executados inteiramente em ambiente Linux. Especificamente, utilizou-se a distribuição Ubuntu instalada via subsistema Windows para Linux (WSL - *Windows Subsystem for Linux*) executando sob um computador pessoal munido do sistema operacional Windows 11. As aplicações Rust compiladas para o target WebAssembly System Interface (`wasm32-wasip1`) foram executadas utilizando o runtime WasmEdge, o qual disponibiliza a sandbox e os recursos de rede adequados para emular a operação distribuída dos nós sensores e servidores locais.

5.2 O Dataset e o Modelo do Tomateiro

O modelo agrônomo do cultivo de tomateiro define faixas recomendadas de temperatura (T) e umidade (H). Neste projeto, o conjunto de treinamento da cultura de tomateiro está mapeado em 11 classes distintas de status, detalhadas na Tabela 2.

Tabela 2 – Tabela de treinamento e categorias da cultura de tomate

Categoria	Símbolo	Nome Agrônômico	T_{min}	T_{max}	H_{min}	H_{max}
0	D	Critical dry	0,0	4,0	0,0	35,0
1	L	Lower fail	0,0	11,0	40,0	65,0
2	M	Marginal	12,0	28,0	40,0	55,0
3	U	Upper Fail	29,0	47,0	40,0	55,0
4	C	Cold and Humid	0,0	11,0	70,0	100,0
5	O	Lower optimal	12,0	14,0	60,0	100,0
6	S	Optimal	15,0	17,0	60,0	100,0
7	P	Upper Optimal	18,0	27,0	60,0	100,0
8	E	Upper Marginal	28,0	31,0	60,0	100,0
9	H	Upper Fail (high hum)	32,0	35,0	60,0	100,0
10	K	Critical	36,0	47,0	60,0	100,0

Fonte: Adaptado de Ribeiro Junior et al. (JUNIOR et al., 2020)

A normalização Min-Max dos dados físicos utiliza os limites globais do sensor: para temperatura, $[0, 0; 47, 0]^{\circ}\text{C}$; para umidade, $[0, 0; 100, 0]\%$. O algoritmo $k\text{NN}$ opera com

$k = 3$, calculando a distância Euclidiana com os centroides normalizados de cada classe da Tabela 2.

5.3 Configuração dos Experimentos de Compressão

Para analisar o desempenho do filtro, avaliamos o processo sob 5 tamanhos de lote de transmissão (tamanho do pacote acumulado antes do envio RLE):

- **Lote 6** (representando 30 segundos de dados físicos);
- **Lote 60** (5 minutos);
- **Lote 720** (1 hora);
- **Lote 4.320** (6 horas);
- **Lote 20.000** (aproximadamente 14 horas de dados contínuos).

O experimento de compressão em lote foi executado 3 vezes independentes. Em cada rodada, gerou-se uma nova base de dados sintéticos via KDE com 40.000 leituras, de modo a garantir a análise de robustez estatística frente à variabilidade estocástica do gerador Rust.

5.4 Planilha de Métricas de Validação

A validação científica da geração de dados estocásticos utilizou três métricas fundamentais:

1. **Teste KS de Duas Amostras:** Aplica-se às séries de temperatura e umidade separadamente. O p-valor limite de rejeição da hipótese nula de igualdade é $\alpha = 0,05$. Se $p > 0,05$, considera-se que o gerador Rust reproduz fielmente a distribuição de probabilidade da base física;
2. **Coeficiente de Correlação de Pearson (r):** Calcula-se o coeficiente linear entre temperatura e umidade para a base real (r_{orig}) e para a base sintética (r_{rust}); a diferença absoluta $|r_{orig} - r_{rust}|$ deve ser inferior a 0,01;
3. **Comparação de Curvas de Contorno e Correlogramas:** Avaliação visual das densidades bidimensionais e da dispersão espacial das classes kNN nas sub-rodadas (Round 1 e Round 2) para verificar a aderência topológica dos dados simulados.

6 RESULTADOS E DISCUSSÃO

6.1 Validação Estatística dos Dados Sintéticos


Os testes estatísticos provaram que o gerador estocástico baseado na estimativa KDE multivariada e implementado em Rust com a transformada de Box-Muller apresenta altíssima fidelidade científica na reprodução do comportamento do sensor físico real.

O teste de Kolmogorov-Smirnov (KS) (MASSEY, 1951) de duas amostras comparou 44.023 leituras reais contra 40.000 leituras sintéticas. O resultado para a temperatura apresentou estatística $D = 0,0080$ com p-valor de 0,1385. Para a umidade, a estatística obtida foi $D = 0,0040$ com p-valor de 0,8974. Sendo ambos os p-valores amplamente superiores a 0,05, aceita-se a hipótese nula H_0 de que ambas as amostras provêm da mesma distribuição populacional contínua.


A correlação física inversa entre temperatura e umidade foi preservada com precisão. O coeficiente de Pearson (PEARSON, 1895) dos dados originais foi calculado em $r_{orig} = -0,8837$, enquanto a base sintética apresentou $r_{rust} = -0,8804$. A diferença absoluta obtida foi de apenas 0,0033 (desvio de 0,37%), demonstrando que o gerador multivariado reproduz com exatidão a interdependência física das variáveis.

6.2 Análise Visual das Curvas de Densidade e Distribuição

A comparação visual das densidades de probabilidade e da classificação espacial revela um comportamento estatístico fundamental sobre o processo de emulação. A Figura 2 exhibe os gráficos de contorno de densidade (equivalentes à Figura 3 do artigo de base) comparando as rodadas reais de dados com as amostras sintéticas correspondentes.



(a) Dados Originais (R1 e R2)



(b) Dados Sintéticos KDE

Figura 2 – Curvas de contorno de densidade de probabilidade bidimensional


Fonte: O Autor (2026)

Percebe-se que as curvas de contorno dos dados originais (Figura 2a) exibem padrões térmicos e de umidade bem delimitados para cada rodada: o Round 1 (período da madrugada) apresenta-se como um cluster concentrado em baixas temperaturas e alta umidade, enquanto o Round 2 (período da manhã) estende-se em uma longa faixa diagonal conforme a temperatura se eleva. Contudo, nas curvas dos dados sintéticos (Figura 2b), tanto a Amostra Sintética 1 quanto a Amostra Sintética 2 apresentam comportamentos quase idênticos, ocupando toda a amplitude diagonal da base completa.


Essa diferença decorre do fato de que o gerador estocástico baseado em KDE é um modelo probabilístico estático e *i.i.d.* (independente e identicamente distribuído). Ele estima a função de densidade conjunta global a partir de todo o conjunto de dados da base física e gera novos pontos por amostragem espacial, sem modelar a correlação temporal ou a ordenação cronológica da série original. Como resultado, ao dividir a base sintética em duas metades ordenadas para representar as duas rodadas temporais, ambas as metades contêm amostras aleatórias que refletem a densidade global conjunta, e não as restrições térmicas locais de cada período.

Os correlogramas detalhados com a coloração dos pontos pelas classes classificadas

pelo algoritmo k NN ($k = 3$), com as curvas de densidade marginais integradas nos eixos (equivalentes à Figura 4 do artigo), são apresentados para as sub-rodadas nas Figuras 3 e 4.



(a) Round 1 - Original



(b) Round 1 - Sintético

Figura 3 – Correlogramas de Temperatura vs Umidade classificados por kNN (Round 1)

Fonte: O Autor (2026)





Figura 4 – Correlogramas de Temperatura vs Umidade classificados por kNN (Round 2)

Fonte: O Autor (2026)

Os correlogramas evidenciam a mesma característica estrutural. Enquanto os dados originais do Round 1 (Figura 3a) concentram-se em temperaturas de 14 a 19°C e classificam os pontos em apenas 3 categorias (*Marginal*, *Optimal* e *Lower optimal*), a versão sintética correspondente (Figura 3b) exibe pontos dispersos ao longo de todo o espectro do dataset global (de 5 a 30°C), ativando classes adicionais como *Upper Fail* e *Cold and Humid*. As distribuições marginais de temperatura e umidade ao longo dos eixos confirmam que as metades sintéticas simulam a densidade global conjunta.

Finalmente, a Figura 5 apresenta a comparação global de contorno bidimensional para a base completa de dados reais e sintéticos.




Figura 5 – Comparação de Densidade Bidimensional Completa (Original vs Sintético)

Fonte: O Autor (2026)

A sobreposição visual na Figura 5 confirma que, sob uma perspectiva de distribuição acumulada global, o gerador KDE em Rust recupera a estrutura estocástica latente com de fato altíssima fidelidade, apresentando contornos e centros de adensamento muito próximos aos da base física real. Entretanto, a perda da ordenação temporal inerente à amostragem *i.i.d.* do KDE introduz uma flutuação de alta frequência nas séries sintéticas. Em dados reais, a temperatura e a umidade mudam lentamente no tempo (baixa frequência), gerando longas sequências contínuas da mesma classe agrônômica. Na série sintética, a flutuação *i.i.d.* faz com que a classe classificada pelo kNN oscile rapidamente entre pontos adjacentes. Esse ruído artificial de alta frequência encurta o comprimento médio das corridas contíguas, o que explica por que o codificador RLE apresenta menor ganho de compressão nos dados simulados do que nos dados reais sequenciais, servindo como uma importante diretriz empírica para projetistas de simuladores de sensores IoT.

6.3 Resultados da Compressão de Dados nos Experimentos

Para caracterizar o impacto do empacotamento na compressão, realizou-se a segmentação da base de dados simulada de 40.000 registros em 5 cenários de lotes distintos. A Tabela 3 apresenta a modelagem e a partição temporal do experimento para a primeira bateria de testes (Experimento 1).

Tabela 3 – Detalhamento da partição dos dados em lotes no Experimento 1

Tamanho do Lote	Escopo Temporal	Qtd. de Lotes	Original Acumulado (B)	kNN Acumulado (B)	RLE Acumulado (B)
6	30 segundos (Micro)	6.667	1.856.634	40.000	70.218
60	5 minutos	667	1.850.634	40.000	68.288
720	1 hora	56	1.850.023	40.000	68.062
4.320	6 horas	10	1.849.977	40.000	67.962
20.000	14 horas (Metade)	2	1.849.969	40.000	68.104

Fonte: O Autor (2026)

A partir do detalhamento de partição, dois fenômenos de engenharia de software e análise de dados podem ser formalizados:

6.3.1 Custo de Serialização JSON e o Overhead de Colchetes

Observa-se na Tabela 3 que o tamanho acumulado dos dados originais (em formato JSON bruto) diminui à medida que o tamanho do lote aumenta, passando de 1.856.634 bytes para 1.849.969 bytes (uma redução líquida de 6.665 bytes). Isso é explicado pelo custo de sintaxe da estrutura de matriz JSON (`[...]`). Cada lote processado adiciona dois caracteres sintáticos (um colchete de abertura e um de fechamento) à string serializada.

- Para lote de tamanho 6, a divisão resulta em 6.667 lotes independentes, introduzindo um overhead de aproximadamente 13.334 bytes apenas em colchetes delimitadores.
- Para lote de tamanho 20.000, o overhead sintático cai para apenas 4 bytes no total (referente aos colchetes dos 2 lotes gerados).

6.3.2 Efeito de Borda e o Lote Ideal

O ponto de maior compressão para a técnica combinada kNN+RLE ocorreu de forma consistente no tamanho de **4.320 registros (6 horas)**, resultando em um payload de **67.962 bytes**. Isso decorre da redução do “efeito de borda”: à medida que o tamanho do pacote aumenta, a probabilidade de uma corrida longa de categorias ser artificialmente interrompida na fronteira de divisão do lote diminui. Isso permite ao RLE formar sequências mais compactas. Contudo, para lotes ainda maiores, como o de **20.000 registros**, o ganho é ligeiramente degradado (subindo para 68.104 bytes). Esse fenômeno decorre da representação numérica decimal das frequências no RLE. Frequências muito longas demandam mais caracteres decimais (exemplo: representar uma contagem de 12.345

repetições da classe **Optimal** consome 6 bytes, 123450, enquanto contagens menores na faixa de dezenas ou centenas consomem de 2 a 3 bytes). O custo extra dos dígitos numéricos adicionais anula as vantagens marginais obtidas na eliminação das quebras de borda.

6.3.3 Consistência entre Execuções Independentes

Para validar a estabilidade estatística do gerador, os experimentos de compressão foram repetidos em três baterias completas com novos dados estocásticos gerados via KDE. A Tabela 4 apresenta o tamanho final do payload em bytes após a codificação kNN+RLE para cada bateria.

Tabela 4 – Tamanhos finais após compactação kNN+RLE (Bytes)

Tamanho do Lote	Experimento 1	Experimento 2	Experimento 3	Desvio Máx.	Var. % Máx.
6	70.218	70.142	70.038	180 B	0,25%
60	68.288	67.982	68.166	306 B	0,44%
720	68.062	68.072	67.932	140 B	0,20%
4.320	67.962	68.194	68.022	232 B	0,34%
20.000	68.104	68.082	68.100	22 B	0,03%

Fonte: O Autor (2026)

A variação máxima observada entre as execuções independentes foi extremamente reduzida (abaixo de 0,44%). Como kNN e RLE são determinísticos, essa flutuação residual decorre unicamente da semente aleatória do gerador estocástico KDE que altera ligeiramente as coordenadas dos pontos de dados simulados nas fronteiras de decisão das classes do tomateiro, alterando pontualmente os padrões de alternância de classes. Isso comprova a elevada estabilidade estatística e reprodutibilidade do gerador.

A Tabela 5 resume as taxas de compressão percentual obtidas para as três baterias de teste em relação à representação original serializada em JSON.

Tabela 5 – Taxas de redução acumuladas (kNN+RLE) em relação ao JSON original (%)

Tamanho do Lote	Experimento 1 (%)	Experimento 2 (%)	Experimento 3 (%)	Variação Máx. (%)
6	96,22%	96,22%	96,23%	0,01%
60	96,31%	96,33%	96,32%	0,02%
720	96,32%	96,32%	96,33%	0,01%
4.320	96,33%	96,31%	96,32%	0,02%
20.000	96,32%	96,32%	96,32%	0,00%

Fonte: O Autor (2026)

Percebe-se que, independente do tamanho de lote utilizado e das flutuações amostrais, a taxa de redução global de dados transmitidos fica estavelmente posicionada acima de 96,2%.

6.4 Comparação kNN Puro vs kNN+RLE

Uma das contribuições mais relevantes deste estudo emerge da comparação direta entre o uso de apenas a classificação kNN (kNN Puro) e a combinação de classificação com codificação de corrida (kNN+RLE). A Tabela 6 traz a comparação média das taxas de redução.

Tabela 6 – Comparação de redução: kNN Puro vs kNN+RLE

Tamanho do Lote	Redução kNN Puro (%)	Redução kNN+RLE (%)	Melhor Opção
6 (30 s)	97,85% (40 KB)	96,22% (70 KB)	kNN Puro (+1,63%)
60 (5 min)	97,84% (40 KB)	96,32% (68 KB)	kNN Puro (+1,52%)
720 (1 h)	97,84% (40 KB)	96,31% (68 KB)	kNN Puro (+1,53%)
4.320 (6 h)	97,84% (40 KB)	96,32% (68 KB)	kNN Puro (+1,52%)
20.000 (14 h)	97,84% (40 KB)	96,32% (68 KB)	kNN Puro (+1,52%)

Fonte: O Autor (2026)

Os dados revelam uma constatação contra-intuitiva: **o kNN Puro comprime mais e gera payloads menores do que o kNN+RLE em todas as configurações**. O kNN Puro reduziu o arquivo final para estáveis 40 KB, enquanto o RLE resultou em arquivos entre 68 KB e 70 KB.

6.4.1 Discussão sobre a Ineficiência do RLE

Esse comportamento deve-se a dois fatores principais decorrentes do alfabeto de símbolos curto do classificador k NN:

1. **Fenômeno de Expansão de Símbolo Único:** O kNN converte cada par de leituras físicas em uma string de um caractere (por exemplo, 0 para *Optimal*). Portanto, 40.000 leituras correspondem a 40.000 caracteres de texto puro, ocupando exatamente 40.000 bytes. Quando o RLE atua, ele agrupa caracteres repetidos na estrutura <frequência><categoria> (ex: 30). Para leituras com baixa repetição consecutiva (comprimento de corrida $C = 1$), o RLE codifica a ocorrência como 10 (ocupando **2 bytes**, o que representa uma expansão de 100% do tamanho original de 1 byte).
2. **Oscilação Natural do Sensor Físico (Ruído de Fronteira):** Como temperatura e umidade flutuam continuamente sob efeito de ruído físico na bacia de captação dos sensores, os dados próximos aos limites de decisão do classificador k NN oscilam constantemente de classe (por exemplo, alternando entre 0, P e S a cada minuto). Essas alternâncias de alta frequência rompem a homogeneidade das corridas contíguas. A grande quantidade de corridas de comprimento unitário ou muito curtas geradas pela variabilidade dos dados causa uma expansão de volume que anula a economia de espaço proporcionada pelas raras corridas longas, resultando em um payload total acumulado de 68 KB a 70 KB para o RLE contra os 40 KB estáveis do kNN Puro.

Essa análise revela que a compactação RLE é inadequada se a codificação do kNN já foi previamente otimizada para 1 caractere de comprimento. O RLE só apresentaria vantagem se o kNN puro exportasse rótulos textuais completos (como "Optimal" e "Upper Marginal"), caso em que o custo de strings de 7 a 15 bytes justificaria o overhead de adicionar contadores.

7 CONCLUSÃO

Este trabalho apresentou uma abordagem robusta e eficiente para a computação em névoa aplicada à IoT agrícola. A migração dos algoritmos de classificação k NN e compressão de dados para Rust compilado em WebAssembly demonstrou a viabilidade de implantar soluções analíticas de alta segurança e portabilidade em gateways de borda reais com baixíssimo consumo de recursos computacionais.

O simulador estocástico desenvolvido em Rust/WASM, fundamentado na Estimativa de Densidade por Kernel (KDE) e na Transformada de Box-Muller, comprovou ser uma ferramenta científica valiosa para modelar e gerar de forma altamente precisa dados sintéticos de sensores locais. Os testes Kolmogorov-Smirnov e a correlação de Pearson atestaram a excelente representatividade física dos dados simulados.

Os experimentos de compressão revelaram a ineficiência prática da combinação do k NN com o RLE em relação ao k NN puro quando o formato do status agrônômico já é otimizado para caracteres únicos de 1 byte. Esse resultado contraria suposições teóricas comuns de projetos de transmissão IoT e serve como uma diretriz empírica crucial para projetistas de sistemas de monitoramento agrícola.

Como trabalhos futuros, propõe-se a validação em campo utilizando gateways LoRaWAN físicos baseados em arquiteturas ARM de baixo custo executando WasmEdge. Sugere-se também a investigação de algoritmos de classificação adaptativos que ajustem dinamicamente o valor de k com base no nível de bateria disponível nos nós sensores, e a aplicação de classificadores robustos a ruídos de fronteira de modo a minimizar as oscilações de classificação que degradam a eficiência da codificação temporal.

Referências

- ADELANTADO, F. et al. Understanding the limits of lorawan. *IEEE Communications Magazine*, IEEE, v. 55, n. 9, p. 34–40, 2017.
- BOX, G. E. P.; MULLER, M. E. A note on the generation of random normal deviates. *The Annals of Mathematical Statistics*, JSTOR, v. 29, n. 2, p. 610–611, 1958.
- HAAS, A. et al. Bringing the web up to speed with webassembly. In: *Proceedings of the ACM SIGPLAN Conference on Programming Language Design and Implementation (PLDI)*. Barcelona, Spain: ACM, 2017. p. 185–200.
- JUNIOR, L. A. S. R. et al. A nearest neighbors based data filter for fog computing in iot smart agriculture. In: *Proceedings of the IEEE International Workshop on Metrology for Agriculture and Forestry (MetroAgriFor)*. Trento, Italy: IEEE, 2020. p. 194–198.
- KAMIENSKI, C. A. et al. Orquestração e gerenciamento no contínuo nuvem-névoa-coisas para a agricultura inteligente. In: *Anais do Workshop de Computação em Nuvem e Névoa (WCF)*. Porto Alegre, Brasil: SBC, 2018. p. 1–8.
- MASSEY, F. J. The kolmogorov-smirnov test for goodness of fit. *Journal of the American Statistical Association*, Taylor & Francis, v. 46, n. 253, p. 68–78, 1951.
- MATSAKIS, N. D.; II, F. S. K. The rust language. *ACM SIGAda Ada Letters*, ACM, v. 34, n. 3, p. 103–104, 2014.
- PEARSON, K. Note on regression and inheritance in the case of two parents. *Proceedings of the Royal Society of London*, v. 58, p. 240–242, 1895.
- SILVERMAN, B. W. *Density Estimation for Statistics and Data Analysis*. London: Chapman & Hall, 1986.
- WasmEdge Runtime. *CNCF WasmEdge*. [S.l.], 2023. Acesso em: junho 2026. Disponível em: <<https://wasmedge.org>>.

APÊNDICE A – ESTRUTURA DO PROJETO DE SENSORES E NÉVOA

A estrutura de diretórios do ecossistema PGC-Rust está organizada da seguinte forma:

```
pgc-rust/
|-- processador/                # Modulo da Nevoa (WASM)
|   |-- Cargo.toml
|   |-- src/
|       |-- main.rs            # Algoritmo kNN, RLE e Gerador KDE
|-- simulador/                  # Componente do dispositivo IoT (Thing)
|   |-- Cargo.toml
|   |-- src/
|       |-- main.rs
|-- receiver/                   # Modulo da Nuvem (Cloud)
|   |-- Cargo.toml
|   |-- src/
|       |-- main.rs
|-- gerador-de-dados/           # Scripts auxiliares e validacao
    estocastica
|   |-- gerar_dados_sinteticos.py
|   |-- gerar_graficos_artigo.py # Gerador de graficos de contorno
|   |-- validar_dados_rust.py    # Executa teste KS e Pearson
|-- analise-experimentos/       # Resultados dos experimentos 1, 2 e 3
|   |-- experimento-1/
|       |-- dados_sinteticos_gerados_rust.csv
|       |-- densidade_artigo_original.png
|       |-- densidade_artigo_sintetico.png
|       |-- correlograma_r1_original.png
|       |-- correlograma_r2_sintetico.png
|-- entrada.csv                 # Base de dados original
|-- run_experiments.sh          # Executa bateria de testes do PGC
```

Listing A.1 – Estrutura de diretórios do PGC-Rust

APÊNDICE B – MODELO DOS DADOS SERIALIZADOS (JSON)

A seguir é apresentado o formato JSON de serialização das estatísticas de compressão exportadas pelo processador em modo lote:

```
{
  "tamanho_lote": 20000,
  "total_registros": 40000,
  "bytes_originais": 1856634,
  "bytes_knn_puro": 40000,
  "bytes_knn_rle": 68104,
  "taxa_reducao_knn": 97.8455,
  "taxa_reducao_rle": 96.3318,
  "experimentos": [
    {
      "lote_id": 0,
      "tamanho": 20000,
      "frequencias_classes": {
        "Optimal": 25421,
        "Upper_Optimal": 12102,
        "Marginal": 2477
      }
    }
  ]
}
```

Listing B.1 – Modelo JSON de Estatísticas de Compressão

APÊNDICE C – COMANDOS DE LINHA DE COMANDO (CLI) E ROTEIRO DE EXECUÇÃO

Para fins de documentação técnica, a seguir são apresentados os comandos no console e as flags necessárias para executar todos os componentes do ecossistema.

C.0.1 Compilação de cada Componente para WebAssembly

Todos os programas em Rust utilizam o compilador `cargo` direcionando a compilação para o target `wasm32-wasip1`. Navegue até a pasta de cada módulo e execute:

```
cargo build --target wasm32-wasip1
```

Listing C.1 – Comando de build dos módulos Rust

C.0.2 Modo Normal (Fluxo Online de Rede)

Neste modo, os componentes escutam em portas TCP locais e comunicam-se via chamadas HTTP. Devem ser iniciados na seguinte sequência:

1. **Receiver na Nuvem (Cloud):** Recebe payloads RLE e grava o log de monitoramento.

```
wasmedge --dir . receiver/target/wasm32-wasip1/debug/receiver.wasm
  [porta] [log_file] [ambiente]
# Exemplo padrao:
wasmedge --dir . receiver/target/wasm32-wasip1/debug/receiver.wasm
  8082 monitoramento.txt Cloud
```

2. **Processador na Névoa (Fog):** Classifica com kNN e executa compressão RLE.

```
wasmedge --dir . processador/target/wasm32-wasip1/debug/processador
  .wasm [porta] [url_receiver] [ambiente]
# Exemplo padrao:
wasmedge --dir . processador/target/wasm32-wasip1/debug/processador
  .wasm 8081 http://localhost:8082/receber Fog
```

3. **Gateway LoRa (Relay):** Proxy para retransmissão de rede física.

```

wasmedge --dir . LoRa/target/wasm32-wasip1/debug/LoRa.wasm [porta]
[url_processador] [ambiente]
# Exemplo padrao:
wasmedge --dir . LoRa/target/wasm32-wasip1/debug/LoRa.wasm 8080
http://localhost:8081/inserir Fog

```

4. **Simulador de Dispositivo IoT (Thing):** Transmite dados brutos a cada 5 segundos.

```

wasmedge --dir . simulador/target/wasm32-wasip1/debug/simulador.
wasm [url_gateway] [ambiente]
# Exemplo padrao:
wasmedge --dir . simulador/target/wasm32-wasip1/debug/simulador.
wasm http://localhost:8080/inserir Thing

```

C.0.3 Modo Lote (Offline / Batch Mode)

Este modo processa arquivos estáticos inteiros, calculando a eficiência global da compressão.

```

wasmedge --dir . processador/target/wasm32-wasip1/debug/processador.wasm
batch [csv_entrada] [json_saida] [flags]
# Exemplo basico:
wasmedge --dir . processador/target/wasm32-wasip1/debug/processador.wasm
batch entrada.csv estatisticas.json

```

Listing C.2 – Execução do modo batch offline

Flags aceitas no modo lote:

- **-tamanho-pacote <N>** ou **-lote-tamanho <N>**: Configura o tamanho de amostras agrupadas em cada pacote RLE (padrão: 6).
- **-synthetic** ou **-sintetico**: Ativa o gerador estocástico baseado em KDE. O processador gerará 40.000 amostras a partir do CSV de entrada com a transformada de Box-Muller, salvará em `dados_sinteticos_gerados_rust.csv` e processará esta série sintética.

```

wasmedge --dir . processador/target/wasm32-wasip1/debug/processador.wasm
batch entrada.csv estatisticas_sintetico.json --synthetic --tamanho-
pacote 720

```

Listing C.3 – Exemplo completo de modo lote com dados sintéticos e lote de 720 registros